

Ajuste de Curvas


Aproximación funcional de datos experimentales y reducción de error



Curso:
Métodos Numéricos




Docente:
Dr. Hermes Pantoja Carhuavilca




Objetivos de la Sesión

01. **Identificar** la diferencia fundamental entre interpolación y regresión.
02. **Aproximar** funciones analíticas a partir de datos discretos utilizando el criterio de mínimos cuadrados.
03. **Formular** y resolver sistemas de ecuaciones normales en su forma matricial.
04. **Aplicar** estos conceptos a casos reales de ingeniería y herramientas de IA.




Fundamentación Teórica: Interpolación vs. Regresión

Interpolación



La curva toca todos los puntos.
Riesgo de oscilaciones en datos ruidosos.


Regresión (Mínimos Cuadrados)



Minimiza la discrepancia global.
Ideal para datos experimentales.

$$\text{Criterio de Minimización: } S_r = \sum_{i=1}^n (y_{i,\text{medido}} - y_{i,\text{modelo}})^2$$

Fundamentación Teórica: El Criterio de Mínimos Cuadrados



Definición de Residuo: $e_i = y_i - (a_0 + a_1 x_i)$

¿Por qué minimizar la suma de cuadrados (S_r)?

- Evita cancelación de signos (vs. suma simple).
- Penaliza valores atípicos (outliers).
- Diferenciable: permite solución analítica.

Función Objetivo:

$$S_r = \sum_{i=1}^n e_i^2 = \sum_{i=1}^n (y_i - a_0 - a_1 x_i)^2$$

Condición de Optimización (Derivadas $\rightarrow 0$):

$$\frac{\partial S_r}{\partial a_0} = -2 \sum_{i=1}^n (y_i - a_0 - a_1 x_i) = 0$$

$$\frac{\partial S_r}{\partial a_1} = -2 \sum_{i=1}^n (y_i - a_0 - a_1 x_i) x_i = 0$$

Las Ecuaciones Normales y Forma Matricial

El motor algorítmico ($A^T A x = A^T b$)

Datos (Conocidos) →

$$\begin{bmatrix} n & \sum x_i \\ \sum x_i & \sum x_i^2 \end{bmatrix} \begin{bmatrix} a_0 \\ a_1 \end{bmatrix} = \begin{bmatrix} \sum y_i \\ \sum x_i y_i \end{bmatrix}$$

Incógnitas

$$\underbrace{A^T A}_{\text{Matriz de Información}} \cdot \underbrace{x}_{\text{Coeficientes}} = \underbrace{A^T b}_{\text{Vector Transformado}}$$

$$x = (A^T A)^{-1} A^T b$$

Matriz de Diseño
(Modelo Cuadrático)


$$A = \begin{bmatrix} 1 & x_1 & x_1^2 \\ 1 & x_2 & x_2^2 \\ \vdots & \vdots & \vdots \\ 1 & x_n & x_n^2 \end{bmatrix}$$

Calidad del Ajuste (r^2)

¿Qué tan bueno es nuestro modelo?

Coeficiente de Determinación (r^2): Mide qué porcentaje de la variabilidad es explicado por el modelo.

$$r^2 = \frac{S_t - S_r}{S_t}$$



S_t : Dispersión total.

S_r : Error residual.

Regresión Polinomial

Modelo: $y = a_0 + a_1x + a_2x^2 + \cdots + a_mx^m$


Matriz de Vandermonde: Se añaden columnas con potencias de x .

Advertencias:

- **Mal Condicionamiento:** Matrices grandes pueden tener determinantes cercanos a cero.
- **Sobreajuste:** Un grado alto ($m \approx n$) captura el ruido, no la tendencia.

$$A = \begin{bmatrix} 1 & x_1 & x_1^2 & \cdots & x_1^m \\ 1 & x_2 & x_2^2 & \cdots & x_2^m \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_n & x_n^2 & \cdots & x_n^m \end{bmatrix}$$

Matriz de Diseño Polinomial




Sobreajuste

Linealización de Modelos No Lineales

Transformación de variables para usar mínimos cuadrados lineales.


**Modelo Exponencial
(Crecimiento/Decaimiento)**

$$y = \alpha e^{\beta x} \rightarrow \ln y = \ln \alpha + \beta x$$



**Ecuación de Potencias
(Leyes de Escala)**

$$y = \alpha x^{\beta} \rightarrow \log y = \log \alpha + \beta \log x$$




**Razón de Crecimiento
(Saturación)**

$$y = \frac{\alpha x}{\beta + x} \rightarrow \frac{1}{y} = \frac{1}{\alpha} + \frac{\beta}{\alpha} \frac{1}{x}$$


Aplicaciones: Industria y Mecatrónica

Ingeniería Industrial Curvas de Aprendizaje



Optimización de inventarios y predicción de costos estables.


Ingeniería Mecatrónica Calibración de Sensores



Corrección digital de no-linealidades en tiempo real.


Aplicaciones: Mecánica y Energía

Ingeniería Mecánica Nuevos Materiales



Caracterización de compuestos y análisis de falla.

Ingeniería de Energía Eficiencia Eólica




Validación de curvas de diseño vs. datos de campo.

Aplicaciones: Ambiental y Civil

Ingeniería Ambiental


Calidad del Agua



Modelo Streeter-Phelps: Determinación de la constante de reaeración k_a .

Ingeniería Civil

Geotecnia



Predicción de asentamientos a largo plazo (Consolidación).

Actividad: El Desafío del Modelo Óptimo

Inteligencia Artificial y Pensamiento Crítico

Code Editor

```
> PROMPT: Genera un script en MATLAB para ajustar datos  $(x, y)$  a un  
modelo exponencial  $y = ae^{bx}$ .  
> 1. Método A: Linealización (polyfit con  $\ln y$ ).  
> 2. Método B: Optimización No Lineal directa (fminsearch).  
> Compara los coeficientes resultantes.
```


Critical Question: ¿Por qué difieren los resultados?

La linealización minimiza $\sum (\ln y - \ln \hat{y})^2$ (error transformado).

La optimización directa minimiza $\sum (y - \hat{y})^2$ (error real).

Conclusión

“El ajuste de curvas no es solo dibujar una línea entre puntos; es el puente entre la observación experimental ruidosa y la formulación de leyes físicas predictivas.”



Referencias Bibliográficas



Chapra, S. C., & Canale, R. P. *Métodos Numéricos para Ingenieros.*

Note: Estándar para aplicaciones y algoritmos.



Burden, R. L., & Faires, J. D. *Análisis Numérico.*

Note: Enfoque riguroso en teoría de error.



Nakamura, S. *Métodos Numéricos Aplicados con Software.*

Note: Implementación computacional y visualización.